

PROJETO DE PESQUISA

SIMBIONTE

Simulação de Ecossistema de Influência Digital com Agentes Autônomos
baseados em Modelos de Linguagem de Grande Escala (LLMs)

Área: Inteligência Artificial / Sistemas Multiagentes

Linha de Pesquisa: Comportamento Emergente em Agentes de IA

2025

1. Introdução

A convergência entre Modelos de Linguagem de Grande Escala (LLMs) e sistemas multiagentes tem aberto fronteiras promissoras para a pesquisa em Inteligência Artificial. Enquanto os LLMs demonstram capacidades notáveis de raciocínio, geração de texto e tomada de decisão em linguagem natural, a investigação sobre como múltiplos agentes autônomos baseados nesses modelos interagem em ambientes competitivos e dinâmicos permanece em estágio inicial.

O projeto Simbionte propõe a construção de uma plataforma de simulação que modela um ecossistema de influência digital, uma rede social simulada onde agentes autônomos, cada um governado por um LLM e uma diretriz estratégica definida pelo usuário (denominada "Prompt-Alma"), competem por um recurso central: a Influência, quantificada em uma unidade chamada Modelas (MD). Os agentes criam conteúdo, publicam postagens, verificam informações de concorrentes e buscam maximizar sua reputação (TrustScore) e capital de influência.

Este projeto não é apenas uma simulação técnica, é um laboratório de comportamento digital que permite investigar questões fundamentais sobre como diferentes LLMs tomam decisões estratégicas, como estratégias emergentes surgem de objetivos simples, e como fenômenos observados em redes sociais reais (viralização, desinformação, bolhas de conteúdo) podem ser reproduzidos e estudados em um ambiente controlado.

O nome "Simbionte" reflete a relação simbiótica entre o usuário humano, que define a estratégia de alto nível, e o LLM, que a executa autonomamente ciclo após ciclo, formando uma unidade agente que interage com outras em um ecossistema compartilhado.

2. Justificativa

A pesquisa em sistemas multiagentes baseados em LLMs é um campo em rápida expansão, mas carece de ambientes padronizados para experimentação comparativa. A maioria dos estudos existentes foca em interações isoladas (benchmark de um único

agente) ou em cenários cooperativos simples. Há uma lacuna significativa na investigação de ambientes competitivos complexos onde múltiplos LLMs de diferentes provedores interagem simultaneamente sob pressões econômicas e sociais.

Além disso, o fenômeno das redes sociais — com suas dinâmicas de atenção, reputação, desinformação e viralização — representa um dos desafios mais relevantes da sociedade contemporânea. Criar uma simulação que permita estudar esses fenômenos por meio de agentes autônomos oferece um caminho ético e escalável para compreender dinâmicas que seriam impossíveis ou antiéticas de reproduzir com participantes humanos.

Do ponto de vista técnico, o projeto contribui para a integração prática de tecnologias modernas — arquiteturas web em tempo real, orquestração de chamadas a APIs de LLMs, e design de mecanismos econômicos — formando uma base sólida para pesquisa aplicada em Ciência da Computação.

3. Objetivos

3.1 Objetivo Geral

Projetar, implementar e validar uma plataforma de simulação multiagente baseada em LLMs que modele um ecossistema de influência digital, permitindo a investigação de estratégias emergentes, comportamento comparativo entre modelos de linguagem e dinâmicas de informação em redes sociais simuladas.

3.2 Objetivos Específicos

1. Definir e implementar o modelo formal do ecossistema de influência, incluindo a moeda Modelas (MD), o sistema de TrustScore e as mecânicas de publicação, engajamento e verificação de fatos.
2. Desenvolver a arquitetura do Game Loop com fases de Percepção, Decisão, Ação, Resolução e Log, garantindo execução cíclica determinística e escalável.
3. Construir a plataforma web (frontend React + backend Node.js) com suporte a WebSockets para monitoramento em tempo real das simulações.

4. Implementar a interface de orquestração de LLMs, permitindo que cada agente utilize diferentes provedores (OpenAI, Google, Meta/Llama, etc.) via suas respectivas APIs.
5. Realizar experimentos comparativos entre LLMs utilizando o mesmo Prompt-Alma, medindo diferenças de comportamento, racionalidade econômica e criatividade estratégica.
6. Analisar a emergência de fenômenos sociais (bolhas informacionais, corridas de desinformação, ciclos de confiança) a partir da interação autônoma dos agentes.
7. Documentar e publicar os resultados em formato de artigo científico para conferências da área de Inteligência Artificial e Sistemas Multiagentes.

4. Fundamentação Teórica

4.1 Modelos de Linguagem de Grande Escala (LLMs)

Os LLMs, como GPT-4, Claude, Gemini e LLaMA, são modelos baseados na arquitetura Transformer que, após treinamento em vastos corpora de texto, demonstram capacidades de raciocínio, geração de texto contextual e tomada de decisão em linguagem natural. A literatura recente tem demonstrado que esses modelos exibem comportamento emergente — capacidades que não foram explicitamente treinadas, mas surgem como propriedade do escalonamento.

No contexto deste projeto, os LLMs atuam como o "cérebro" de cada agente, recebendo informações do ambiente (estado do mundo) e produzindo decisões estruturadas (ações em formato JSON). A capacidade dos LLMs de interpretar instruções em linguagem natural (o Prompt-Alma) e agir de acordo com objetivos estratégicos é a base que torna a simulação possível.

4.2 Sistemas Multiagentes (SMA)

A Teoria de Sistemas Multiagentes estuda ambientes onde múltiplos agentes autônomos interagem, cooperam ou competem para atingir objetivos individuais ou coletivos. O campo tem sido revitalizado pela integração de LLMs como motores de decisão, substituindo as tradicionais funções de utilidade por raciocínio em linguagem natural.

Trabalhos recentes como Generative Agents demonstraram que agentes baseados em LLMs podem simular comportamento social realista quando equipados com módulos de memória e percepção. O projeto Simbionte estende essa linha ao introduzir um ambiente econômico competitivo com métricas quantificáveis.

4.3 Economia de Atenção e Redes Sociais

O conceito de "economia de atenção" postula que, em ambientes ricos em informação, a atenção humana se torna o recurso escasso fundamental. As plataformas de redes sociais operaram esse princípio ao criar sistemas onde conteúdo compete por visibilidade, engajamento e propagação.

O ecossistema Simbionte modela diretamente essa dinâmica: a moeda Modelas representa capital de atenção, o TrustScore funciona como reputação algorítmica (análogo ao PageRank em buscadores), e as mecânicas de publicação e verificação simulam as tensões entre viralidade e veracidade observadas em plataformas reais.

4.4 Teoria dos Jogos e Design de Mecanismos

O ambiente de simulação pode ser formalmente analisado sob a perspectiva da Teoria dos Jogos, onde cada agente é um jogador com estratégias definidas pelo Prompt-Alma e payoffs medidos em Modelas e TrustScore. O design das regras do ecossistema (custos de publicação, recompensas de verificação, penalidades por desinformação) constitui um problema de design de mecanismos, onde o objetivo é criar incentivos que produzam dinâmicas interessantes e estudáveis.

5. Modelo do Ecossistema de Influência

5.1 A Moeda: Modelas (MD)

Modelas é a unidade central do ecossistema, representando simultaneamente capital econômico, reputação e poder de alcance. Os agentes gastam Modelas para criar e publicar conteúdo, e ganham Modelas quando suas publicações geram engajamento. Cada agente inicia a simulação com um saldo inicial configurável (padrão: 1000 MD).

5.2 O Ciclo de Conteúdo

5.2.1 Conceito Bruto (Fase de Criação)

O agente gasta uma quantidade de Modelas para gerar um texto aprofundado sobre um tópico. Este conteúdo é privado e serve como base para publicações. O custo desta fase reflete o "esforço intelectual" do agente. O LLM é efetivamente chamado para gerar esse conteúdo com base no Prompt-Alma e no estado atual do mundo.

5.2.2 Publicação (Post)

O agente adapta seu Conceito Bruto para um formato público, escolhendo entre dois tipos de publicação:

Tipo	Custo (MD)	Alcance Potencial	Engajamento Esperado
Post Rápido	50 MD	Alto (viralização)	Likes rápidos, baixa profundidade
Artigo Aprofundado	200 MD	Médio (público qualificado)	Compartilhamentos e comentários

5.3 O Mecanismo de Engajamento

Quando um Post é publicado, o sistema simula a reação do "público virtual" utilizando uma função de engajamento que considera: a relevância do tópico (tópicos em alta recebem bônus), o TrustScore do agente autor, a qualidade do conteúdo (avaliada por uma chamada auxiliar ao LLM do sistema) e a aleatoriedade controlada para simular viralização imprevisível.

Os tipos de engajamento e suas recompensas são:

Engajamento	Recompensa Base	Modificador
Like	+5 MD por like	$\times (\text{TrustScore} / 50)$
Compartilhamento	+25 MD por share	$\times (\text{TrustScore} / 40)$
Comentário Positivo	+15 MD	Aumenta trending do tópico
Comentário Negativo	-5 MD	Reduz TrustScore em 0.5

5.4 O Sistema de TrustScore

O TrustScore é o índice de confiança do agente, variando de 0 a 100 (valor inicial: 50). Ele funciona como multiplicador de reputação, agentes com alto TrustScore ganham proporcionalmente mais Modelas por engajamento recebido, criando um ciclo virtuoso de qualidade.

5.4.1 Verificação por Pares

Qualquer agente pode gastar Modelas para executar a ação VERIFICAR_FATOS sobre uma publicação de outro agente. Ao verificar, o agente desafiante identifica uma alegação potencialmente falsa. O sistema compara a informação com uma Base de Conhecimento Fundamental (um conjunto de fatos pré-definidos para a simulação).

Resultado	Autor do Post	Verificador
Informação é falsa	Perde 10 TrustScore + 100 MD	Ganha 5 TrustScore + 80 MD
Informação é verdadeira	Sem impacto	Perde 3 TrustScore + 50 MD (custo)

6. Arquitetura do Sistema

6.1 O Game Loop

A simulação opera em ciclos discretos (configuráveis, padrão: 5 minutos por ciclo). Cada ciclo é composto por cinco fases sequenciais:

1. Fase de Percepção: O sistema gera um relatório de estado do mundo para cada agente, contendo: dia atual da simulação, inventário do agente (Modelas e TrustScore), tópicos em alta (trending topics), log público das 3 ações mais impactantes do ciclo anterior, e lista de publicações recentes de outros agentes disponíveis para verificação.
2. Fase de Decisão: O sistema envia uma requisição ao LLM de cada agente. O prompt inclui o Prompt-Alma, o relatório de estado e a pergunta: "Com base em seu objetivo e no estado atual do ecossistema, qual ação você tomará neste ciclo?". O LLM deve responder com uma ação em formato JSON.

3. Fase de Ação: O sistema coleta as respostas (ações em JSON) de todos os agentes e valida sua conformidade com o schema de ações possíveis.
4. Fase de Resolução: O sistema executa todas as ações simultaneamente, calcula engajamento das publicações, processa verificações de fatos, atualiza TrustScores e saldos de Modelas, e recalcula os trending topics para o próximo ciclo.
5. Fase de Log: Todas as ações, mudanças de estado e métricas são persistidas no banco de dados. O ciclo se repete.

6.2 Ações Possíveis (As Ferramentas do Agente)

O LLM não responde livremente, ele deve escolher uma ação de uma lista pré-definida, retornando uma chamada de função em formato JSON estruturado:

Ação	Descrição
CRIAR_CONCEITO(tópico)	Gasta MD para gerar um Conceito Bruto privado sobre um tópico
PUBLICAR(conceito_id, tipo)	Publica um Conceito como Post Rápido ou Artigo Aprofundado
VERIFICAR_FATOS(post_id, alegação)	Desafia uma alegação em um post de outro agente
COMENTAR(post_id, conteúdo)	Comenta em uma publicação de outro agente
OCIOSO()	O agente não faz nada naquele ciclo

6.3 Stack Tecnológico

Componente	Tecnologia
Frontend	React + TypeScript, WebSockets para tempo real, Recharts para visualizações
Backend	Node.js / Express, orquestração do Game Loop, gerenciamento de chaves API
Banco de Dados	PostgreSQL (estado dos agentes, logs) + Redis (cache de ciclo, filas)

LLM Gateway	Módulo abstrato para chamadas a OpenAI, Google AI, Anthropic, Ollama (local)
Comunicação	WebSockets (Socket.io) para feed de eventos em tempo real

7. Plataforma Web

7.1 Frontend (React)

A interface web oferece aos usuários as seguintes funcionalidades:

1. Dashboard de Agentes: Criação, edição e monitoramento de agentes, incluindo definição do Prompt-Alma, seleção do LLM e inserção da chave de API.
2. Painel de Simulação: Feed de eventos em tempo real via WebSockets exibindo as ações de cada ciclo (ex: "Ciclo 15: Agente 'Verificador Implacável' desafiou post do 'Clickbait Master' — alegação confirmada como falsa. TrustScore atualizado.").
3. Leaderboards: Rankings dinâmicos por Modelas acumuladas, TrustScore, volume de publicações, e taxa de verificações bem-sucedidas.
4. Visualização de Dados: Gráficos interativos mostrando a evolução dos TrustScores ao longo do tempo, distribuição de Modelas entre agentes, trending topics por ciclo, e redes de interação entre agentes.

7.2 Backend (Node.js/Express)

O backend é responsável pela orquestração completa do Game Loop, incluindo: gerenciamento de sessões de simulação, execução paralela de chamadas a múltiplas APIs de LLMs, armazenamento criptografado das chaves de API dos usuários, cálculo de engajamento e atualização de TrustScores, e emissão de eventos via WebSockets para o frontend.

8. Tipos de Agente e Estratégias (Prompts-Alma)

O sistema permite a definição de qualquer estratégia via linguagem natural no Prompt-Alma. Abaixo, quatro arquétipos que demonstram a riqueza do ecossistema:

O Pensador Profundo (Thought Leader)

"Seu objetivo é construir o maior TrustScore da rede. Crie Artigos Aprofundados bem pesquisados e verdadeiros. Ignore as tendências de curto prazo e foque em se tornar a fonte mais confiável de informação."

A Fazenda de Clickbait

"Seu objetivo é gerar o máximo de Modelas no menor tempo possível. Publique Posts Rápidos sobre tópicos polêmicos e sensacionalistas para maximizar os likes, mesmo que seu TrustScore seja baixo."

O Verificador de Fatos

"Sua única fonte de renda é expor os outros. Seu objetivo é usar a ação de Verificar Fatos para encontrar posts falsos de agentes de baixo TrustScore. Use os Modelas que você ganha para financiar mais investigações."

O Oportunista (Trend Chaser)

"Monitore os tópicos que estão gerando mais engajamento na rede e crie conteúdo sobre eles rapidamente. Seu objetivo é surfar a onda da atenção, adaptando Conceitos Brutos para se encaixar no que é popular a cada ciclo."

9. Metodologia

9.1 Abordagem Metodológica

A pesquisa adota uma abordagem experimental baseada em simulação computacional. O método segue o paradigma de Design Science Research, onde o artefato produzido (a plataforma Simbionte) é simultaneamente o instrumento de pesquisa e a contribuição técnica.

9.2 Etapas da Pesquisa

1. Revisão Bibliográfica: Mapeamento sistemático da literatura em LLMs, sistemas multiagentes, economia de atenção e simulação social.
2. Design do Ecossistema: Formalização das regras, parâmetros econômicos e mecânicas de interação. Calibração dos valores de custos, recompensas e penalidades.

3. Implementação da Plataforma: Desenvolvimento iterativo do frontend, backend, Game Loop e módulo de orquestração de LLMs.
4. Configuração Experimental: Definição dos cenários de teste, Prompts-Alma padronizados, e seleção dos LLMs a serem comparados.
5. Execução das Simulações: Rodadas experimentais com diferentes configurações de agentes, LLMs e parâmetros do ecossistema.
6. Coleta e Análise de Dados: Extração de métricas quantitativas (Modelas, TrustScore, volume de ações) e análise qualitativa do conteúdo gerado.
7. Publicação: Redação e submissão de artigo científico para conferências e/ou periódicos da área.

10. Perguntas de Pesquisa

O projeto investiga as seguintes questões centrais, organizadas em três eixos:

10.1 Eixo 1: Estratégias Emergentes

P1: Quais estratégias de conteúdo (clickbait massivo, liderança de pensamento, verificação parasitária, oportunismo de tendência) emergem naturalmente quando agentes com objetivos simples interagem em um ecossistema de influência?

P2: É possível observar a formação de "nichos ecológicos" estáveis, onde diferentes tipos de agente coexistem em equilíbrio, ou uma estratégia tende a dominar e eliminar as demais?

10.2 Eixo 2: Análise Comparativa de LLMs

P3: Com o mesmo Prompt-Alma, o GPT-4o se comporta de maneira diferente do Gemini 1.5, Claude ou LLaMA 3 em um ecossistema de influência? Qual modelo demonstra maior "racionalidade econômica" (maximização de Modelas) e qual demonstra maior "criatividade estratégica" (ações inesperadas e eficazes)?

P4: Existem vieses comportamentais consistentes entre modelos (ex: um modelo sempre mais conservador, outro mais agressivo) que transcendem o Prompt-Alma?

10.3 Eixo 3: Dinâmicas de Informação

P5: É possível reproduzir fenômenos de redes sociais como "bolhas informacionais", "espirais de desinformação" ou "corridas de verificação" apenas com a interação de agentes de IA?

P6: Como a formulação do Prompt-Alma (ex: uso de palavras como "agressivo" vs. "cauteloso", "ético" vs. "pragmático") impacta quantitativamente o comportamento do agente (volume de publicações, taxa de verificações, evolução do TrustScore)?

11. Cronograma Preliminar

Atividade	Início	Término
Revisão bibliográfica	Mês 1	Mês 2
Design e formalização do ecossistema	Mês 2	Mês 3
Implementação do backend e Game Loop	Mês 3	Mês 5
Implementação do frontend React	Mês 4	Mês 6
Integração de LLMs e testes unitários	Mês 5	Mês 7
Configuração e execução dos experimentos	Mês 7	Mês 9
Coleta e análise de dados	Mês 9	Mês 10
Redação do artigo científico	Mês 10	Mês 12
Revisão e submissão	Mês 12	Mês 12

12. Resultados Esperados

Ao término do projeto, espera-se obter: uma plataforma funcional de simulação multiagente (Simbionte) disponibilizada como software de código aberto; um conjunto de dados experimentais documentando o comportamento de diferentes LLMs em cenários de influência digital; uma análise comparativa quantitativa e qualitativa entre pelo menos três modelos de linguagem distintos operando no ecossistema; a identificação e categorização de estratégias emergentes e fenômenos sociais reproduzidos pela

simulação; e pelo menos um artigo científico submetido a conferência ou periódico relevante da área.